

Metody Numeryczne, Projekt 2

Hleb Badzeika

Styczeń 2024

1 Krótki opis metody

Dekompozycja LDL jest metoda faktoryzacji macierzy, która rozkłada hermitowska, dodatnio określona macierz A na iloczyn trzech macierzy: dolnej trójkątnej L , diagonalnej D oraz hermitowskiego sprzężenia dolnej trójkątnej L^H . Matematycznie, dekompozycje te można wyrazić jako:

$$A = LDL^H$$

gdzie:

- A jest hermitowska, dodatnio określona macierza.
- L jest dolna macierz trójkątna z jedynkami na głównej przekątnej.
- D jest macierz diagonalna.
- L^H jest hermitowskim sprzężeniem L , co oznacza dolna macierz trójkątna złożona z elementów zespolonych sprzężonych do odpowiadających im elementów w L .

Dekompozycja LDL jest szczególnie użyteczna do rozwiązywania równań liniowych postaci $Ax = b$, gdzie A jest macierz hermitowska. W przypadku macierzy rzeczywistych, sprzężenie hermitowskie L^H redukuje się do transpozycji L^T , a dekompozycja przyjmuje postać LDL^T .

Dla danej hermitowskiej, dodatnio określonej macierzy A , metoda Cholesky'ego–Banachiewicza pozwala na znalezienie takiej dolnej macierzy trójkątnej L , że $A = LDL^H$, gdzie L^H oznacza sprzężenie hermitowskie macierzy L , a D jest macierz diagonalna.

Proces rozkładu dla macierzy pentadiagonalnej A odbywa się według poniższego schematu:

1. Rozpoczynamy od pierwszej kolumny macierzy A i wyznaczamy elementy macierzy L oraz D .
2. Dla każdego i -tego wiersza macierzy A , obliczamy element l_{ii} jako pierwiastek kwadratowy z $a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2 d_{kk}$.

3. Elementy poza przekatną macierzy L , l_{ij} dla $j < i$, obliczamy korzystając z wzoru:

$$l_{ij} = \frac{1}{d_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk}^* d_{kk} \right)$$

, gdzie l_{jk}^* oznacza sprzężenie zespolone elementu l_{jk} .

4. Po obliczeniu wszystkich elementów macierzy L i D , możemy rozwiązać równanie $XA = B$ poprzez podstawienie $A = LDL^H$ i rozwiązanie dwóch równań trójkatnych: $LY = B$ oraz $L^H X = D^{-1}Y$.

W przypadku macierzy pentadiagonalnej, operacje te są bardziej efektywne ze względu na mniejszą liczbę niezerowych elementów w macierzy A .

2 Krótki opis programu

Implementacja w MATLAB-ie algorytmu dekompozycji LDL skupia się na obsłudze hermitowskich, pięcioprzekatnych, dodatnio określonych macierzy. Kod składa się z kilku funkcji:

2.1 Przegląd implementacji

Program zawiera następujące funkcje:

- `LDLDecomposition(A)`: Rozkłada macierz A na LDL^H .
- `solveLDLH(A, B)`: Rozwiązuje równanie $XA = B$ za pomocą dekompozycji LDL.
- Funkcje do generowania macierzy testowych: Różne funkcje do tworzenia specyficznych typów macierzy do testowania.

2.2 Opis funkcji

2.2.1 `LDLDecomposition(A)`

Wejście: Hermitowska, pięcioprzekatna, dodatnio określona macierz A .

Wyjście: Macierze L i D z rozkładu $A = LDL^H$.

Funkcja ta wykonuje rozkład LDL macierzy A , zwracając dolną macierz trójkatną L i macierz diagonalną D , tak że $A = L * D * L^H$.

2.2.2 `solveLDLH(A, B)`

Wejście: Macierz A oraz macierz B o odpowiednich wymiarach.

Wyjście: Rozwiązanie X równania $XA = B$.

Funkcja ta wykorzystuje rozkład LDL macierzy A do rozwiązania równania $XA = B$, stosując do tego celu metodę podstawienia w przód i wstecz.

2.3 Funkcje do generowania macierzy testowych

Opracowane funkcje służą do generowania macierzy dla konkretnych przypadków testowych, każda z nich tworzy macierz o unikalnych właściwościach:

2.3.1 `generateWellConditionedMatrix(n)`

Wejście: Rozmiar macierzy n .

Wyjście: Dobrze uwarunkowana, hermitowska, pięcioprzekatna, dodatnio określona macierz.

Funkcja ta generuje dobrze uwarunkowaną macierz, zapewniając umiarkowane wartości własne dla stabilności numerycznej.

2.3.2 `generateIllConditionedMatrix(n)`

Wejście: Rozmiar macierzy n .

Wyjście: Źle uwarunkowana, hermitowska, pięcioprzekatna, dodatnio określona macierz.

Ta funkcja tworzy macierz źle uwarunkowaną poprzez zastosowanie szerokiego zakresu wartości własnych, co czyni ją numerycznie trudniejszą do rozwiązania.

2.3.3 `generateLargeMatrix(n)`

Wejście: Rozmiar macierzy n .

Wyjście: Duża, hermitowska, pięcioprzekatna, dodatnio określona macierz.

Funkcja generuje dużą macierz, co pozwala na ocenę wydajności i skalowalności algorytmu.

2.3.4 `generateMatrixWithSmallElements(n)`

Wejście: Rozmiar macierzy n .

Wyjście: Macierz z małymi elementami, hermitowska, pięcioprzekatna, dodatnio określona.

Ta funkcja tworzy macierz z bardzo małymi liczbami, testując precyzję algorytmu w warunkach bliskich precyzji maszynowej.

2.3.5 `generateMatrixWithRandomNoise(n)`

Wejście: Rozmiar macierzy n .

Wyjście: Macierz z losowym szumem, hermitowska, pięcioprzekatna, dodatnio określona.

Funkcja dodaje losowy szum do dobrze uwarunkowanej macierzy, symulując tym samym rzeczywiste dane, które mogą nie być idealnie ustrukturyzowane.

2.3.6 generateMatrixWithStructuredPattern(n)

Wejście: Rozmiar macierzy n .

Wyjście: Macierz o określonym wzorze strukturalnym, hermitowska, pięcio-przekatna, dodatnio określona. Ta funkcja tworzy macierz z wykorzystaniem specyficznego, powtarzającego się wzoru liczbowego, zachowując przy tym jej własności hermitowskie i dodatnio określone.

2.4 Analiza i testowanie


Do analizy i testowania wydajności algorytmu wykorzystano szereg przypadków testowych. Każdy przypadek został rozwiązany przy użyciu opracowanego algorytmu, a następnie dokładnie zanalizowano wyniki, biorąc pod uwagę błędy i czas obliczeń. Dodatkowo, wykorzystano techniki wizualizacji, takie jak mapy ciepła, do lepszego zrozumienia rozkładu błędów.

3 Ciekawe przykłady

Analiza czasu wykonania jest zrobiana dla macierzy 1000x1000 dla dokładniejszych wyników. Widać że różnica w czasie wykonania jest niewielka, około 5%. Widać również że pattern błędu resztkowego też jest prawie taki sam dla wszystkich testcasów (oprócz ostatniego, o nim później), dlatego możemy powiedzieć, że jak już mamy macierz A z zadanymi warunkami, to algorytm działa stabilnie.

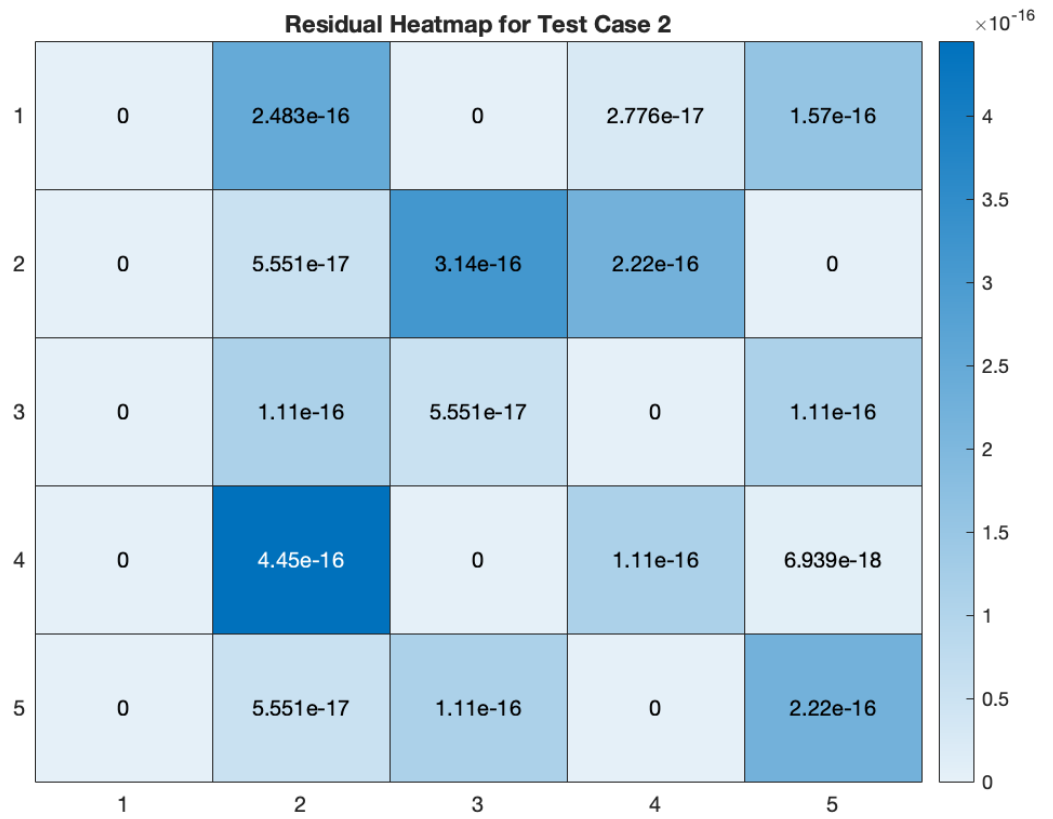
3.1 Dobrze uwarunkowana macierz

Czas wykonania: 0.9597 s



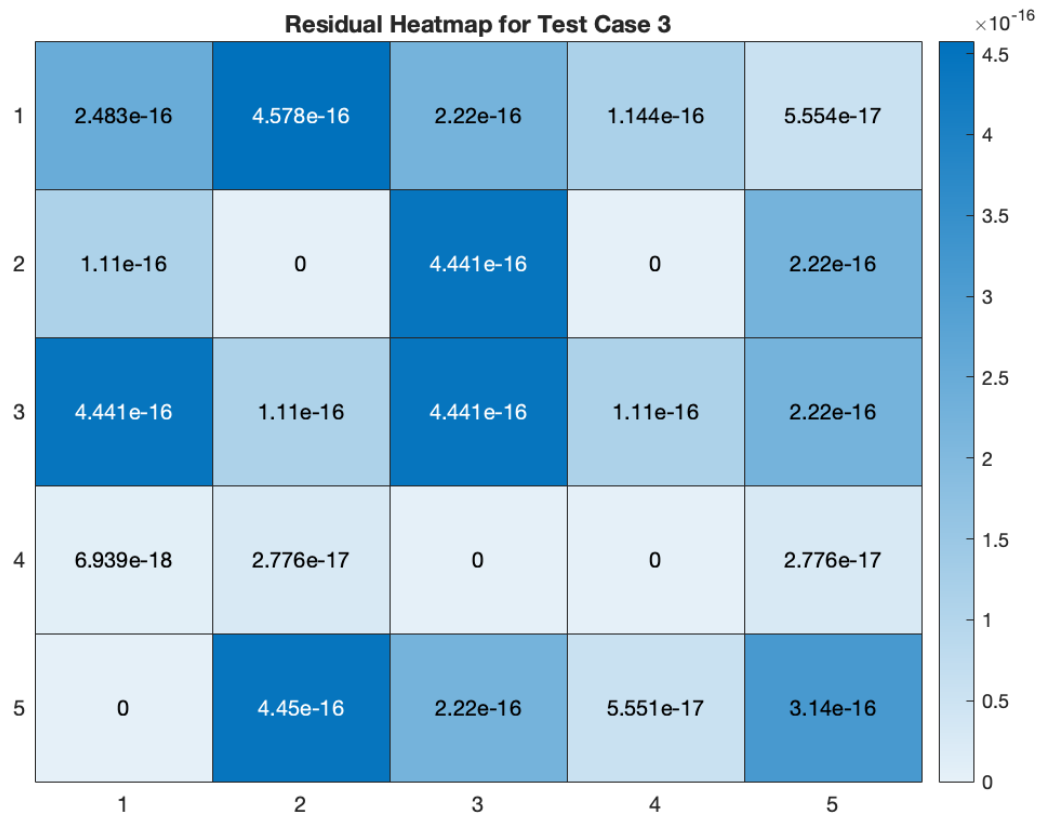
3.2 Zle uwarunkowana macierz

Czas wykonania: 0.8776 s



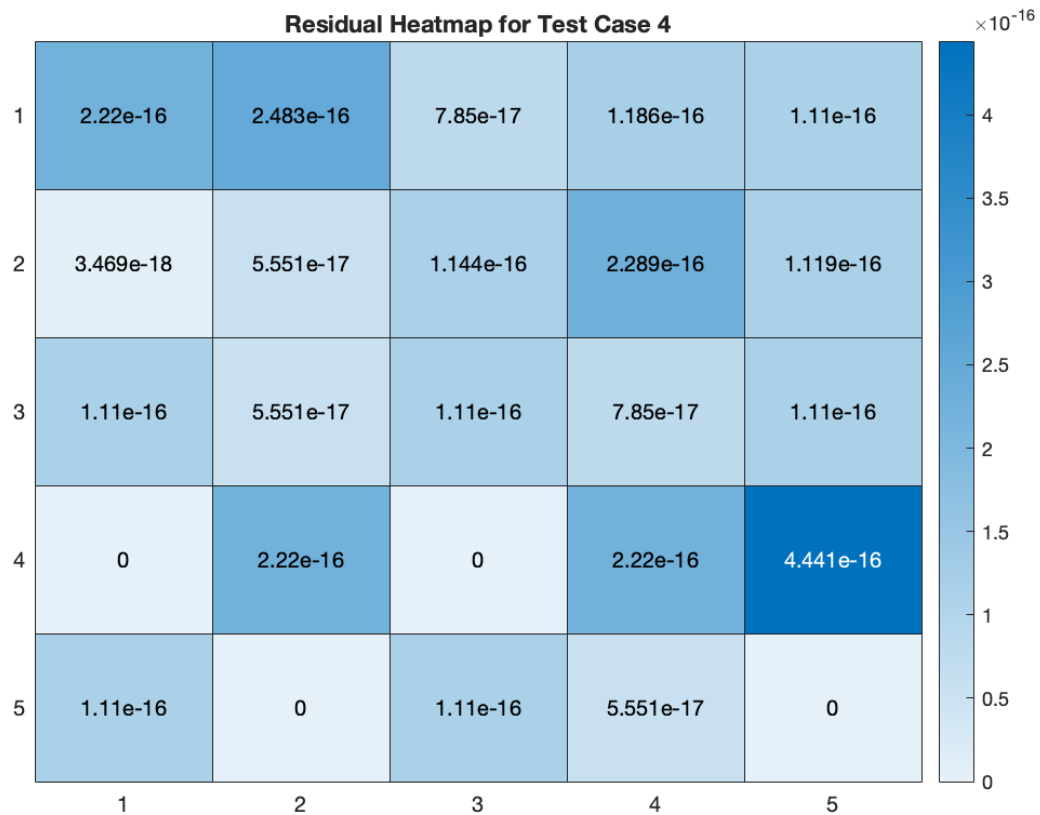
3.3 Macierz z dużymi elementami

Czas wykonania: 0.9469 s




3.4 Macierz z małymi elementami

Czas wykonania: 0.8844 s



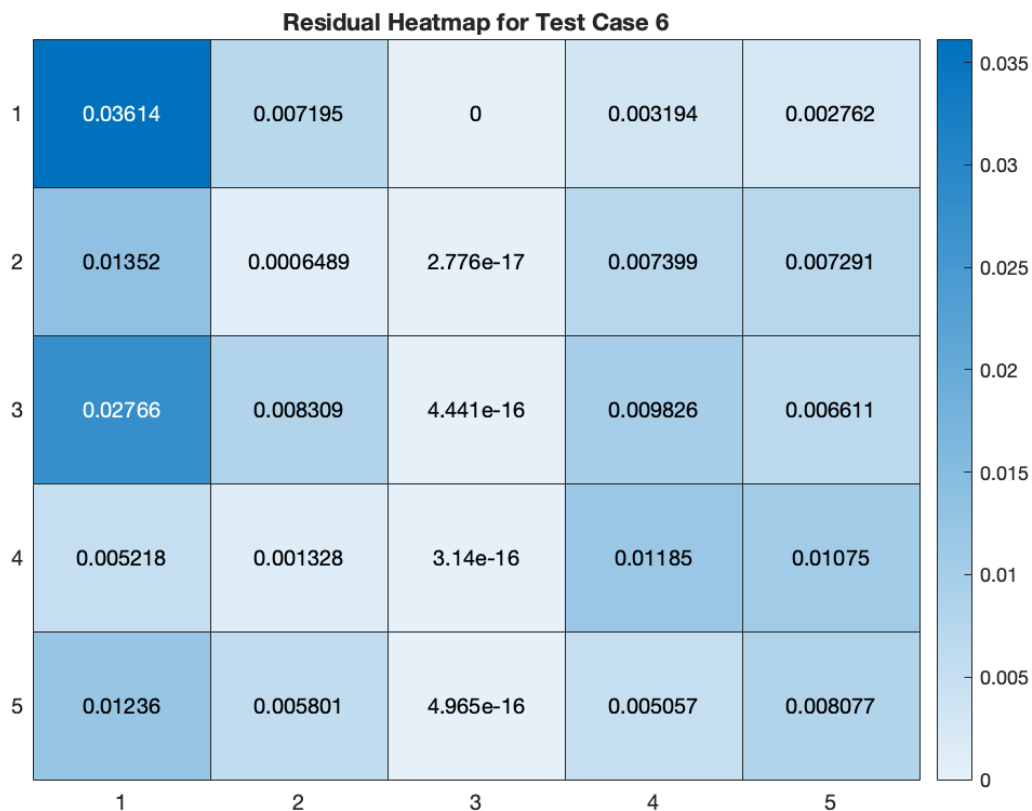
3.5 Macierz z wyróżnionym patternem

Czas wykonania: 0.8319 s



3.6 Macierz z dodatkowum szumem

Czas wykonania: 0.8371 s



Widać, że dodając szum do danych. Otrzymujemy błąd na kilka porządków gorszy niż w pozostałych testcase'ach. To może świadczyć o tym że ten algorytm może być nie najlepszym dla wykorzystania w praktyce na nieprzygotowanych danych.

4 Zastosowanie metody w praktycznym użyciu

Dekompozycja LDL znajduje wiele praktycznych zastosowań, zwłaszcza w dziedzinach takich jak uczenie maszynowe i nauka o danych. Poniżej przedstawiono kilka przykładów takich zastosowań:

4.1 Optymalizacja w Uczeniu Maszynowym

W uczeniu maszynowym dekompozycja LDL jest wykorzystywana do rozwiązywania problemów optymalizacji, szczególnie w algorytmach opartych na metodach kwadratów najmniejszych i optymalizacji wypukłej. Na przykład, w algo-

rytmach takich jak Maszyny Wektorów Wspierających (SVM), dekompozycja LDL może być używana do efektywnego rozwiązywania równań liniowych, które są kluczowe dla znalezienia hiperpłaszczyzny rozdzielającej.

4.2 Analiza Głównych Składowych (PCA)

W naukach o danych, szczególnie w analizie głównych składowych (PCA), dekompozycja LDL może być stosowana do efektywnej faktoryzacji macierzy kowariancji. Pozwala to na redukcję wymiarowości danych, zachowując przy tym istotne informacje statystyczne, co jest szczególnie ważne w przypadku dużych zbiorów danych.